
Datos y datasets

Kaleido FlowTwin

Álvaro Schwiedop Souto

Industrial AI & Predictive Quality Lead

EVOCON Solutions GmbH

15 julio 2026

Índice

1. Datos y datasets	1
1.1. Regla principal	1
1.2. Prioridad A - datos internos del piloto	1
1.2.1. A1. Trace Port	1
1.2.2. A2. Shipping Board	1
1.2.3. A3. Freight Intelligence	2
1.2.4. A4. Coste y planificacion	2
1.3. Prioridad B - contexto externo	2
1.3.1. DCSA Track & Trace y Port Call	2
1.3.2. OCEL 2.0 / XES	2
1.3.3. Meteo y oceanografia	2
1.3.4. AIS	2
1.4. Prioridad C - datasets publicos para desarrollo	3
1.4.1. Container Logistics Object-centric Event Log (2026)	3
1.4.2. BPI Challenge 2019	3
1.4.3. Outbound Warehouse Processes	3
1.4.4. LaDe	3
1.4.5. BPI logs adicionales	3
1.5. Datos sinteticos	3
1.6. Manifest obligatorio	3
1.7. Quality gates	4
1.8. Presupuesto de datos para go/no-go	4

1 Datos y datasets

1.1 Regla principal

Los datasets publicos sirven para desarrollar loaders, schemas y baselines. Solo los datos de Kaleido pueden demostrar valor para Kaleido.

1.2 Prioridad A - datos internos del piloto

1.2.1 A1. Trace Port

Campos solicitados:

- proyecto, operacion, turno y revision de plan;
- packing list/unidades de carga;
- evento/estado y timestamp;
- responsable/equipo/recurso por rol;
- cantidad/peso/unidad;
- notas, incidencia y referencia de foto;
- inicio/fin/pausas;
- outcome y desviacion;
- export/API version y zona horaria.

Uso: caso principal de tiempo restante y riesgo de desviacion.

1.2.2 A2. Shipping Board

- expedicion/recepcion;
- milestones, documentos y alertas;
- transportista y ventanas;
- timestamps planificados/reales;
- incidencias y entrega final.

Uso: transferencia del mismo modelo de prefijos a flujos de instalaciones.

1.2.3 A3. Freight Intelligence

- contenedor, viaje, buque y carrier;
- milestones DCSA-like;
- ETA original y revisiones;
- AIS/posicion o referencias;
- alertas y excepciones;
- timestamps de consulta y de ocurrencia.

Uso: ETA/excepcion, no mezclar con eventos de terminal sin mapping.

1.2.4 A4. Coste y planificacion

- plan original y revisiones;
- horas/recurso;
- overtime, espera, demurrage/detention cuando aplique;
- SLA/penalizacion;
- coste de inspeccion y falsa alarma.

Uso: convertir metricas en utilidad. Opcional para el primer modelo, necesario para un business case cuantitativo.

1.3 Prioridad B - contexto externo

1.3.1 DCSA Track & Trace y Port Call

Estandar de procesos, eventos y APIs para transporte de contenedores. Usar como referencia semantica, no asumir que Trace Port usa exactamente DCSA.

- <https://dcsa.org/standards/track-and-trace/standard-documentation-track-and-trace>
- <https://developer.dcsa.org/>
- <https://reference.dcsa.org/content/standards/industry-blueprint/v2026-q1/industry-blueprint-2026-q1>

1.3.2 OCEL 2.0 / XES

OCEL es preferible para proyecto-operacion-turno-carga-recurso. XES se puede exportar para herramientas classicas de process mining.

- <https://www.ocel-standard.org/>
- <https://www.tf-pm.org/resources/xes-standard/about-xes>

1.3.3 Meteo y oceanografia

- Puertos del Estado/Portuscopia: oleaje, nivel, corrientes, temperatura, mareografos y meteo portuaria.
- AEMET OpenData: observaciones/predicciones meteorologicas.

Fuentes:

- <https://portuscopia.puertos.es/>
- <https://www.puertos.es/en/services/oceanography>
- https://www.aemet.es/en/datos_abiertos/AEMET_OpenData

Verificar licencia, estacion, latencia, revision y timestamp de publicacion. Una prediccion historica solo puede usar el forecast disponible en ese momento, no la observacion futura.

1.3.4 AIS

NOAA MarineCadastre publica AIS de EE. UU. sin restricciones de acceso para planificacion costera. Es util para desarrollar pipelines de trayectoria y port-call context, no representa Vigo ni prueba el caso Kaleido.

- <https://www.fisheries.noaa.gov/inport/item/77594>
- <https://marinecadastre.gov/ais/>

Para Vigo se necesita una fuente legal/contractual disponible para Kaleido.

1.4 Prioridad C - datasets publicos para desarrollo

1.4.1 Container Logistics Object-centric Event Log (2026)

Log artificial OCEL 2.0 de coordinacion de pedido, documento, recogida, terminal y envio. Incluye modelo CPN y SQLite/XML.

- Uso: tests de object graph, import OCEL, process discovery y CI.
- No uso: metricas comerciales o afirmacion de generalizacion real.
- Fuente: <https://zenodo.org/records/18373888>.

1.4.2 BPI Challenge 2019

Log real de purchase-to-pay con 251.734 items, 1.595.923 eventos y 42 actividades, anonimizado y XES.

- Uso: escalabilidad, remaining time/next-event y baselines PPM.
- No uso: evidencia portuaria.
- DOI: <https://doi.org/10.4121/uuid:d06aff4b-79f0-45e6-8ec8-e19730c248f1>.

1.4.3 Outbound Warehouse Processes

Caso de 2025 con 169.523 trazas de un proceso real de almacen outbound. El paper indica disponibilidad publica; antes de descargar se debe localizar el release oficial, version y licencia.

- Uso: comparacion boosting vs deep PPM.
- Fuente primaria: <https://arxiv.org/abs/2509.18986>.

1.4.4 LaDe

Dataset industrial de last-mile con paquetes y task events multi-ciudad.

- Uso: generalizacion espaciotemporal/last-mile opcional.
- No uso: terminal portuaria.
- Fuente: <https://arxiv.org/abs/2306.10675>.

1.4.5 BPI logs adicionales

Solo para pretraining/benchmark de event encoders. Separar por dataset y no presentar un promedio que oculte fallos por log.

- <https://www.tf-pm.org/resources/logs>

1.5 Datos sinteticos

La simulacion discreta y el CPN pueden producir eventos para:

- tests y fixtures;
- fallos raros controlados;
- comprobar invariantes y escenarios;
- pretraining experimental claramente etiquetado.

No se usan para estimar precision real, ROI ni frecuencia de incidencias.

1.6 Manifest obligatorio

```
dataset_id: trace_port_export_v1
owner: kaleido
source_system: trace_port
export_version: unknown
access_date: YYYY-MM-DD
license_or_agreement: pending
timezone_source: Europe/Madrid
rows: measured
```

```
operations: measured
projects: measured
date_min: measured
date_max: measured
sha256: measured
contains_personal_data: unknown
contains_photos: false
plan_revisions_available: unknown
outcomes_available: unknown
action_columns: []
context_columns: []
observation_columns: []
outcome_columns: []
forbidden_columns: []
known_limitations: []
```

1.7 Quality gates

- IDs estables y cobertura de relaciones;
- timezone y orden temporal;
- duplicados/reintentos;
- plan vs actual distinguibles;
- granularidad/event vocabulary;
- missingness por proyecto y periodo;
- outcome y censura;
- accion/context audit;
- riesgo de leakage;
- representatividad por carga/cliente/puerto;
- consentimiento/licencia/retencion.

1.8 Presupuesto de datos para go/no-go

No se exige un numero magico. La decision usa:

- operaciones completas;
- diversidad de variantes;
- numero de eventos por prefijo;
- cobertura de plan y outcome;
- suficientes desviaciones/incidencias;
- estabilidad de IDs;
- separacion temporal disponible.

Si faltan outcomes, el piloto pasa a `instrument-first`: process mining, simulacion y plan de captura, sin clasificador de riesgo.