

Kaleido FlowTwin

Guion de la presentación del MVP

EVOCON Solutions – Álvaro Schwiedop Souto

2026-07-16

Estado de evidencia: smoke_only. El objetivo de la reunión no es afirmar que el modelo ya funciona para Kaleido, sino demostrar un MVP ejecutado, explicar qué se ha aprendido y acordar el acceso a una operación real para un replay shadow.

Mapa rápido

Duración objetivo	20–22 minutos de presentación + 10 minutos de preguntas.
Petición final	Sesión de 90 minutos sobre una operación repetible y 3–5 casos pseudonimizados.
Idea central	Shipping Board informa; Freight Intelligence analiza; FlowTwin anticipa ETA y excepciones.
Resultado principal	ETA AIS: 1.88 h de MAE, 60.6 % dentro de ± 2 h y 6/6 gates aprobados.
Límite	Es evidencia pública de capacidad, no precisión Kaleido, ROI ni despliegue.

Antes de empezar

- Abrir la presentación HTML a pantalla completa y dejar el dashboard preparado en otra pestaña.
- Comprobar que el watermark **smoke_only** es visible y que el dashboard muestra la evidencia ETA AIS.
- No empezar por JEPA. Empezar por el problema operativo y llegar a JEPA como resultado de I+D falsable.
- Tener preparada la pregunta final: operación, responsables, muestra y fecha.

1. Guion diapositiva a diapositiva

Diapositiva 1 – FlowTwin Predictive Operations

0:45

Objetivo. Situar la propuesta y marcar desde el primer minuto la frontera de evidencia.

Qué decir. “Gracias por el tiempo. Hemos construido un MVP técnico de una capa predictiva read-only. El demostrador principal estima la llegada de buques a una zona portuaria a partir de AIS, muestra ventanas de incertidumbre y conserva toda la trazabilidad. No venimos a presentar resultados de Kaleido: venimos a enseñar una idea ejecutada sobre datos públicos y un protocolo para validarla de forma segura con vosotros.”

No decir: “Ya predice vuestras operaciones”, “gemelo autónomo” o “ahorro demostrado”.

Transición: “Primero quiero encajar la idea dentro de lo que Kaleido ya tiene.”

Diapositiva 2 – Encaje en productos Kaleido

1:15

Objetivo. Dejar claro que FlowTwin complementa productos existentes.

Qué decir. “Shipping Board y Freight Intelligence son el encaje inmediato para una ETA explicable: anticipar llegada, detectar excepciones y priorizar qué revisar. Trace Port aporta después la memoria de operaciones, turnos e incidencias; TWINPORTS, el estado físico y espacial. FlowTwin no compite con esos productos: convierte sus eventos en una predicción con intervalo, cutoff y razones.”

Pregunta opcional. “¿En qué pantalla toma hoy una decisión el responsable de turno cuando una operación empieza a desviarse?”

Transición: “Con ese encaje como restricción, construimos el MVP completo de extremo a extremo.”

Diapositiva 3 – MVP y límites explícitos

1:10

Objetivo. Resumir el alcance y convertir las invalidaciones en prueba de disciplina.

Qué decir. “Construimos dos demostradores alineados: ETA con AIS para Shipping Board y Freight Intelligence, y proceso objeto-céntrico OCEL para Trace Port/TWINPORTS. JEPA queda como línea de I+D sometida a ablations. Mantuvimos viajes y operaciones enteros en cada partición, elegimos modelos en validación y reservamos un test futuro del 1 al 7 de febrero. Los runs que no pasaron el protocolo se conservaron como auditoría y no entraron en la cifra.”

No decir: Presentar M0–M7 como un despliegue productivo. Son hitos técnicos de smoke.

Transición: “Veamos exactamente qué datos y protocolo sostienen las cifras.”

Diapositiva 4 – Dataset y protocolo

1:20

Objetivo. Dar credibilidad sin confundir dominio público con dominio portuario.

Qué decir. “Procesamos 38 días de NOAA MarineCadastre AIS, 6.92 GB comprimidos. Una geofence define la llegada y cada prefijo usa solo lo visible en ese instante. El split contiene 303 viajes de entrenamiento, 73 de validación y 85 de test futuro, con 1,780 predicciones en ese test. MMSI se excluyó como feature y ningún viaje cruza particiones. El dataset OCEL secundario aporta 1,966 contenedores.”

Frase clave. “Es una prueba técnica real de ETA portuaria en EE. UU., no una prueba de precisión en Vigo.”

Transición: “Antes de entrenar nada, los eventos ya permiten inteligencia de proceso.”

Diapositiva 5 – Process intelligence**1:00**

Objetivo. Mostrar valor temprano aunque ML no supere los gates.

Qué decir. “El ejemplo OCEL conserva contenedores, vehículos y revisiones de plan como objetos distintos. El grafo correcto bajó el MAE de test de 88.17 a 86.64 horas, pero validación eligió la traza plana, así que cerramos el gate predictivo. Aun así, el bloque ya permite mapas de proceso, variantes, esperas, rework y conformance sin depender de que gane un modelo.”

Transición: “En el demostrador de ETA sí obtuvimos un resultado concreto sobre futuro no visto.”

Diapositiva 6 – Comparación de modelos**1:40**

Objetivo. Explicar el número principal, sus comparadores y el gate fijado antes del test.

Qué decir. “El modelo elegido solo en validación obtiene 1.88 horas de MAE en 85 viajes futuros. El error mediano es 1.37 horas y el bootstrap por viaje da un IC95 % de 1.70 a 2.08. No lo juzgamos solo: la ETA distancia/velocidad tiene 7.79 horas y la mediana por puerto y distancia, 2.73. El modelo mejora un 75.9 % y un 31.2 %, respectivamente.”

Traducción operativa. “El 42.0 % queda dentro de ± 1 hora, el 60.6 % dentro de ± 2 y el 87.3 % dentro de ± 4 . Pasa los seis gates predeclarados: volumen, MAE, extremo del intervalo, tolerancia y mejora contra dos baselines.”

No decir: Llamarlo precisión Kaleido, SOTA o prometer que ± 2 horas sea su tolerancia de negocio.

Transición: “Una predicción operativa no puede ser solo una cifra puntual.”

Diapositiva 7 – Incertidumbre y riesgo**1:15**

Objetivo. Defender intervalos, abstención y semántica del target.

Qué decir. “Por horizonte, el MAE es 1.96 horas cuando faltan 0–2, 1.49 entre 2 y 6, y 2.13 entre 6 y 12. El intervalo P90 cubre 94.5 %, pero mide 9.04 horas de ancho medio: la cobertura se consigue con una banda todavía demasiado amplia. Además, Nueva Orleans concentra 87.6 % de los prefijos de test.”

Conclusión. “La predicción puntual funciona como demostrador; el siguiente trabajo falsable es calibrar por puerto, medir peor grupo y hacer que el sistema se abstenga.”

Transición: “Con el baseline fijado, podemos preguntar qué está aprendiendo realmente JEPA.”

Diapositiva 8 – Ablations de Event-JEPA**2:00**

Objetivo. Explicar por qué JEPA sigue siendo interesante aunque no gane el benchmark.

Qué decir. “La referencia multi-horizonte obtiene 763.51. El encoder aleatorio queda en 772.78, por lo que el objetivo JEPA sí aporta representación downstream. Sin SIGReg el MAE sube a 811.95 y aparece colapso: la regularización es esencial. Pero completion-only obtiene 763.03, ligeramente mejor, y los pares temporales barajados quedan en 763.91. La diferencia temporal es pequeña e inconsistente por seed. Todavía no hemos demostrado una dinámica futura multihorizonte rica.”

Mensaje de investigación. “JEPA aporta señal, pero cada parte debe ganarse su lugar mediante una ablation que pueda falsarla.”

Transición: “Por eso repetimos el experimento con mecanismos más cercanos a T-JEPA y Var-JEPA.”

Diapositiva 9 – T-JEPA, Var-JEPA y el gate híbrido**2:15**

Objetivo. Explicar en lenguaje simple qué se cambió y por qué boosting sigue ganando.

Qué decir. “En la primera versión el target aún contenía el prefijo y compartía encoder. En Temporal T-JEPA hicimos tres cambios con sentido temporal: el target contiene solo eventos futuros, un teacher suavizado por EMA produce el target sin gradiente y elegimos SiGReg, VISReg o token de registro únicamente en validación. Gana multi-VISReg con 759.38 ± 1.15 : mejora al Event-JEPA anterior, y el futuro correcto gana al barajado en tres de tres semillas, pero no supera boosting ni demuestra ventaja multihorizonte estable.”

Continuación. “Var-Event-JEPA sustituye el único punto latente por distribuciones: contexto, una variable auxiliar y futuro tienen media y varianza; el ELBO combina reconstrucción, generación y KL. Obtiene 760.41 ± 6.25 . Su incertidumbre latente tiene Spearman medio 0.045 con el error y falla en dos semillas. Finalmente añadimos los embeddings al boosting: validación conserva raw. El mejor híbrido elegido, raw+Var, obtiene 738.98 ± 0.60 , 4.60 minutos peor que raw.”

ELI5. “Boosting recibe directamente reloj, progreso, actividad y espera. JEPA intenta resumir una película de pocos eventos; en este log el resumen comprime más información de la que descubre. Con objetos, planes, contexto y acciones reales la película sería más rica, pero eso hay que medir, no asumir.”

No decir: Decir que se reprodujeron exactamente T-JEPA o Var-T-JEPA. Son adaptaciones temporales CPU-budgeted y el resultado es `smoke_only`.

Transición: “La pregunta siguiente es si un canal de acción permite aprender transiciones condicionadas.”

Diapositiva 10 – World model sintético con VISReg**2:00**

Objetivo. Mostrar la investigación de acciones sin convertirla en un claim causal.

Qué decir. “No renombramos actividades del log como acciones. Creamos un overlay separado con acciones, elegibilidad, propensión, coste y efecto conocido. El primer benchmark tabular y el Action-JEPA con SIGReg fallaron sus gates. Con VISReg, la acción correcta obtiene 725.75 ± 3.20 frente a 740.43 barajada: gana en tres de tres seeds, con 14.67 minutos de mejora media. El rango efectivo sube a 15.41–16.16, pero la escala sigue en 0.020–0.023, bajo el umbral. Recuperamos una señal inyectada; no promocionamos el world model.”

No decir: “La acción reduce 14,67 minutos en la realidad”. La magnitud pertenece al target generado.

Transición: “*Esto conduce a una separación clara entre producto e investigación.*”

Diapositiva 11 – Decisión de producto**1:00**

Objetivo. Convertir los resultados en una arquitectura de producto prudente.

Qué decir. “La demo sirve ETA AIS, comparadores, tolerancias, intervalo y auditoría read-only. OCEL demuestra process intelligence con identidad de objetos. Temporal T-JEPA, Var-JEPA, acciones reales y object graphs permanecen como I+D con gates. El predictor histórico de almacén con 734 minutos queda conservado como resultado negativo: no se sirve ni se usa para vender la idea.”

Transición: “*La integración propuesta mantiene esa separación y no escribe en sistemas fuente.*”

Diapositiva 12 – Arquitectura complementaria**1:10**

Objetivo. Explicar el flujo read-only y la trazabilidad de cada predicción.

Qué decir. “AIS o Shipping Board aportan posición y contexto de viaje; Trace Port, eventos y turnos; TWINPORTS, activos y espacio. El contrato temporal conserva planes versionados. El baseline ETA, process mining y JEPA shadow producen punto, intervalo y razones; la salida vuelve a una pestaña o API read-only. Cada resultado muestra cutoff, versión y procedencia. El humano sigue decidiendo.”

No decir: Hablar de control automático, escritura en TOS/ERP o optimización autónoma.

Transición: “*La forma más clara de entenderlo es verlo en una interfaz de operación.*”

Diapositiva 13 – Demo del dashboard**2:30**

Objetivo. Enseñar cómo se consumiría el software, sin vender el fixture como Kaleido.

Secuencia de demo.

1. Señalar el watermark `smoke_only` y el modo read-only.
2. Abrir la evidencia ETA: 1.88 h, IC95 % y 85 viajes futuros.
3. Comparar boosting con la ETA cinemática y la mediana puerto-distancia.
4. Mostrar los porcentajes dentro de ± 1 , ± 2 y ± 4 horas y los 6/6 gates.
5. Abrir incertidumbre y límites: intervalo P90, reparto por puerto y abstención.
6. Recorrer procedencia: fechas de test, exclusión de MMSI, hashes y model card.
7. Terminar en la separación: ETA demostrable; OCEL diagnóstico; JEPA en I+D.

Frase de cierre de demo. “La interfaz es el ejemplo de consumo; los valores son sintéticos/públicos. En piloto, esta misma superficie se alimentaría de un export congelado.”

Transición: “*Para convertir la demo en evidencia Kaleido proponemos cuatro gates pequeños.*”

Diapositiva 14 – Piloto con Kaleido**1:15**

Objetivo. Pedir una acción concreta, no una aprobación abstracta.

Qué decir. “Primero validamos esquema y semántica sobre 3–5 casos. Después congelamos planes, revisiones y outcomes. Ejecutamos un replay shadow durante 4–8 semanas, con falsas alertas, lead time, cobertura, peor grupo y utilidad de operador. Solo entonces decidimos integración, buyer, coste y packaging.”

Petición literal. “¿Podemos agendar una sesión de 90 minutos con una persona de Trace Port y una persona de operaciones para elegir una operación y revisar 3–5 casos pseudonimizados?”

Transición: “*La propuesta se resume en una sola frase.*”

Diapositiva 15 – Cierre**0:35**

Qué decir. “Shipping Board informa. Freight Intelligence analiza. FlowTwin anticipa. Ya existe una prueba de ETA sobre futuro no visto y un marco objeto-céntrico para procesos. El siguiente paso no es prometer generalización: es acordar operación, tolerancia, muestra y fecha para medirlo con datos Kaleido.”

Acción. Callar y esperar respuesta. No rellenar el silencio con detalles técnicos.

2. Preguntas previsibles

¿Por qué JEPA si boosting gana?	Porque Temporal T-JEPA mejora al JEPA anterior y distingue futuros correctos de barajados, pero los embeddings no añaden valor incremental al boosting. Se mantiene shadow como hipótesis para datos con acciones, objetos y contexto más ricos.
¿Esto es un world model?	Es un experimento de transición latente condicionado por acciones generadas. Recupera señal inyectada, pero no supera el gate de estabilidad y no tiene acciones Kaleido.
¿Qué hace falta de Kaleido?	IDs pseudonimizados, eventos con timestamps, plan original y revisiones con <code>valid_from</code> , outcomes, objetos y acciones realmente controlables.
¿Cuántos datos?	Primero 3–5 casos para semántica. El volumen de entrenamiento se decide después de medir variantes, eventos por operación, censura y prevalencia del outcome.
¿Puede escribir o controlar equipos?	No. El MVP y la API son read-only y advisory.
¿Cuál es el ROI?	Todavía no se ha medido. En shadow se separan tiempo de reporting, evitabilidad simulada, aceptación del operador y valor realizado.
¿Por qué el intervalo es tan ancho?	Porque refleja heterogeneidad e incertidumbre del dataset. Se muestra para permitir abstención; no se estrecha de forma cosmética.
¿1,88 horas es bueno o malo?	Para este demostrador pasa los seis criterios fijados antes del test y mejora dos comparadores. Además, 60.6 % cae dentro de ± 2 h. No sabemos si esa tolerancia sirve a Kaleido: debe acordarse por decisión y horizonte.
¿Qué ocurrió con los 734 minutos?	Era el MAE de otro dataset de almacén, unas 12,2 h. Ganaba por poco a baselines débiles, pero la escala absoluta y los intervalos no servían como demostrador. Se rechazó para producto y se conserva solo como evidencia auditable.
¿El test representa todos los puertos?	No. 87.6 % de sus prefijos son de Nueva Orleans; Houston y Los Ángeles tienen menos viajes y Nueva York no aparece en el test. Por eso el siguiente gate es por puerto y, después, Vigo/Kaleido.

3. Versiones por tiempo

Si solo hay 10 minutos: diapositivas 1, 2, 4, 6, 7, 11, 14 y 15. Omitir JEPA o resumirlo como línea de I+D que todavía no gana el gate.

Si hay 30 minutos: recorrido completo, demo de 4–5 minutos y preguntas tras la diapositiva 10 antes de cerrar con el piloto.

4. Fuentes y recordatorio de claims

- [NOAA MarineCadastre AIS 2025](#).
- [OCEL 2.0 Container Logistics](#).
- [Kaleido Shipping Board](#) y [Freight Intelligence](#).
- [Kaleido Trace Port](#).
- [Kaleido TWINPORTS](#).
- [LeJEPA](#); [LeWorldModel](#); [VISReg](#); [T-JEPA](#); [Var-JEPA](#).

Recordatorio final. Dataset/export y hash, split, modelos/baselines, métrica e incertidumbre, seeds, selección de umbral, influencia de test y claim state deben acompañar cualquier resultado. Los datos públicos o sintéticos no prueban valor Kaleido.