

Kaleido FlowTwin

Informe técnico y ejecutivo del MVP

EVOCON Solutions – Álvaro Schwiedop Souto

2026-07-16

Estado de toda la evidencia: smoke_only. Los datos públicos y sintéticos demuestran competencia técnica del pipeline; no demuestran precisión, valor, causalidad, ahorro ni despliegue para Kaleido.

Resumen ejecutivo

Se implementó y ejecutó una capa read-only de inteligencia operativa con ETA, incertidumbre, OCEL/process mining, baselines, modelos secuenciales, Event-JEPA, Temporal T-JEPA, Var-Event-JEPA, API y dashboard. El demostrador principal usa 38 días de NOAA MarineCadastre AIS y predice entrada en una geofence portuaria. **Boosting ETA**, elegido solo en validación, obtiene 1.88 horas de MAE en 85 viajes futuros del 1 al 7 de febrero de 2025, con bootstrap por viaje IC95 % 1.70–2.08.

La mediana del error es 1.37 horas; 42.0 % de los puntos queda dentro de ± 1 hora, 60.6 % dentro de ± 2 y 87.3 % dentro de ± 4 . Mejora 75.9 % a una ETA distancia/velocidad y 31.2 % a la mediana puerto-distancia. Pasa los seis gates predeclarados del nuevo holdout. La cobertura P90 es 94.5 %, pero su anchura media de 9.04 horas obliga a mostrar incertidumbre y abstención.

El segundo dataset, OCEL 2.0 Container Logistics, prueba contratos objeto-céntricos y revisiones de plan. El grafo correcto reduce el MAE de test de 88.17 a 86.64 horas, pero validación seleccionó la traza plana; el gate del grafo permanece cerrado. Este resultado se usa para process intelligence y como diagnóstico de I+D, no como claim predictivo.

Temporal T-JEPA incorpora futuros disjuntos, teacher EMA y selección de regularización solo en validación. Mejora al Event-JEPA anterior con 759.38 ± 1.15 , pero no a raw boosting. Var-Event-JEPA obtiene 760.41 ± 6.25 y su incertidumbre latente no sigue el error en todas las seeds. El mejor híbrido elegible, raw + Var-JEPA, obtiene 738.98 ± 0.60 , 4.60 minutos peor que raw; el gate de promoción queda cerrado.

La recomendación es demostrar ETA y ventanas dentro de Shipping Board/Freight Intelligence, llevar process intelligence a Trace Port/TWINPORTS y mantener JEPA como módulo shadow sujeto a gates. Ningún resultado público prueba precisión o valor para Kaleido.

1. Hipótesis y encaje con Kaleido

Hipótesis principal. A partir de posiciones AIS y prefijos causales de eventos, el sistema puede estimar ETA/tiempo restante con incertidumbre y, con datos Kaleido, riesgo de desviación material con lead time accionable.


Shipping Board y Freight Intelligence aportan la superficie natural para ETA y excepciones. Trace Port declara eventos, turnos, equipos, packing lists, incidencias, histórico y API; TWINPORTS desarrolla estado físico y espacial. FlowTwin no debe competir con ellos: debe consumir posiciones/eventos versionados y devolver salidas read-only dentro de los productos existentes.

2. Datos, provenance y protocolo

Dataset principal	NOAA MarineCadastre AIS 2025, 38 días, 6.92 GB comprimidos
Dominio	Cargueros/petroleros en Nueva York, Houston, Los Ángeles y Nueva Orleans
Task	Horas hasta entrada en geofence circular, con prefijos entre 12 h y 15 min
Split	Futuro fijo por viaje: 303 / 73 / 85 viajes
Test	1–7 febrero 2025; 1,780 puntos; MMSI excluido del modelo
Dataset secundario	OCEL 2.0 Container Logistics, 1,966 contenedores y 12,184 prefijos
Selección	Variantes y gates con validación; el test futuro no eligió modelo ni umbral
Seeds	3 (41, 42, 43) para los benchmarks alineados
Claim state	smoke_only

El primer AIS test se invalidó como evidencia de presentación por contener solo 25 viajes. El segundo test de 73 viajes falló el gate subhorario predeclarado. Ambos se preservaron; el protocolo final mantuvo puertos/features/modelos, convirtió enero en desarrollo/validación y reservó febrero como nuevo futuro intacto. También se conservan tres runs históricos invalidados por fuga o selección con test.

3. Resultado principal: ETA AIS



Modelo	MAE h	Mediana AE	± 1 h	± 2 h	Decisión
Boosting ETA	1.88	1.37	42.0 %	60.6 %	seleccionado
Híbrido físico-residual	1.88	–	–	–	segundo
Mediana puerto-distancia	2.73	–	–	–	baseline histórico
ETA distancia/velocidad	7.79	–	–	–	baseline físico

Los seis gates predeclarados pasan: al menos 50 viajes, MAE máximo 2,5 h, extremo superior del IC95 % menor de 3 h, al menos 50 % dentro de ± 2 h y mejoras mínimas frente a ambos baselines. Por horizonte, el MAE es 1.96 h a 0–2 h, 1.49 h a 2–6 h y 2.13 h a 6–12 h.

Límites. 87.6 % de los prefijos de test pertenecen a Nueva Orleans. La cobertura P90 de 94.5 % usa intervalos de 9.04 h de anchura media. Las geofences son circulares inferidas y el dominio es EE. UU. El resultado habilita un demostrador de capacidad, no una promesa operativa para Kaleido.

4. Process intelligence

El loader OCEL público procesó 35,372 eventos, 13,882 objetos y 74,272 relaciones evento-objeto, con 47 variantes e integridad de grafo aprobada. Este bloque funciona sin entrenamiento y es el primer valor del piloto: variantes, tiempos de espera, rework, cuellos de botella, conformance y calidad temporal.

5. Experimento histórico rechazado: Warehouse remaining time

Este benchmark se conserva por auditabilidad y para estudiar JEPA, pero se retira de la demostración predictiva. Su escala absoluta e intervalo no resultan adecuados frente al nuevo ejemplo AIS.

Modelo	Seeds	MAE min	SD/IC	P90	Decisión
Boosting histórico	1	734.51	IC 697.99–771.49	90.02 %	referencia
Raw boosting rerun	3	734.38	SD 0.23	–	no servir
Raw + Var-JEPA	3	738.98	SD 0.60	–	rechazado
Temporal T-JEPA	3	759.38	SD 1.15	–	shadow I+D
Var-Event-JEPA	3	760.41	SD 6.25	–	shadow I+D
Event-JEPA frozen	3	763.51	SD 2.84	93.12 %	shadow I+D
ProcessTransformer	3	809.54	SD 17.89	–	no supera floor

5.1. Por qué los aproximadamente 700 minutos no son el demostrador

El MAE histórico de 734.51 minutos equivale a 12.24 horas de error absoluto medio. La comparación relativa dentro del protocolo sigue siendo válida: mejora 6.9 % a la mediana global y 5.8 % a la mediana por actividad. Sin embargo, ganar por poco a baselines débiles no convierte la escala absoluta en una predicción presentable.


La lectura tampoco debe quedarse en la media. El error absoluto mediano de boosting es 363.98 minutos, frente a 353.15 de la mediana global; por tanto, la mejora de MAE procede sobre todo de reducir errores grandes, no de ganar en cada caso típico. El peor grupo, S, alcanza 1045.82 minutos. La cobertura P90 es 90.02 % con anchura media 2459.90 minutos, 41.00 horas. Ese intervalo amplio evidencia incertidumbre elevada y debe mostrarse.

La conclusión es de rechazo: este predictor no se sirve ni se usa como ejemplo comercial. Se mantiene como resultado negativo que motivó buscar una tarea más cercana a Shipping Board/Freight Intelligence. El benchmark AIS expresa error en horas, supera gates absolutos y compara contra una ETA física; aun así continúa en `smoke_only`.

5.2. Proxy de riesgo

No existe plan versionado en el dataset, por lo que el target es duración larga por encima del P75 de training, no desviación material. AUPRC 0.567, ECE 0.223 y 33.97 falsas alertas por 100 operaciones son diagnósticos de desarrollo. No habilitan alerta portuaria ni claim de early warning.

6. Event-JEPA y ablations



Variante	MAE	SD	Lectura
Main multi-horizon + SIGReg	763.51	2.84	referencia seleccionada en validación
Completion-only + SIGReg	763.03	1.77	multi-horizonte no aporta mejora
Shuffled temporal pairs	763.91	2.15	diferencia media 0.40; no consistente por seed
Random encoder, no JEPA	772.78	2.67	el objetivo JEPA aporta señal
Multi-horizon sin SIGReg	811.95	13.90	colapso; regularizador necesario

La interpretación correcta no es “JEPA gana”. Es: (1) hay valor de representación frente a encoder aleatorio; (2) SIGReg es necesario en el log; (3) no se ha validado ventaja multi-horizonte; (4) el emparejamiento temporal apenas cambia el downstream, por lo que aún no hay evidencia robusta de dinámica futura rica.

7. Temporal T-JEPA, Var-JEPA y boosting híbrido

Temporal T-JEPA corrige dos debilidades de la primera implementación: el target contiene solo el sufijo futuro y un teacher EMA con stop-gradient produce la representación objetivo. La regularización se eligió entre SiGReg, VISReg y token de registro usando validación. `multi_visreg` obtiene 759.38 ± 1.15 ; completion-only obtiene 761.43 y el futuro barajado 762.91. El futuro correcto gana al barajado en 3/3 seeds, pero multi-horizonte no gana a completion-only en todas.


Var-Event-JEPA sustituye el punto latente determinista por distribuciones gaussianas de contexto, variable auxiliar y futuro. El ELBO combina reconstrucción, generación y términos KL. Obtiene 760.41 ± 6.25 ; la correlación Spearman media entre incertidumbre latente y error es 0.045, con dos seeds negativas. Esa incertidumbre es diagnóstica y no está calibrada en minutos.

El experimento híbrido entrena raw, raw+T-JEPA, raw+Var-JEPA y raw+ambos con el mismo split y tres seeds. Validación selecciona raw. Entre híbridos selecciona `raw_var_jepa`, que obtiene 738.98 ± 0.60 , frente a 734.38 ± 0.23 de raw. La diferencia de 4.60 minutos cierra el gate de promoción.

Lectura ELI5. Boosting ve directamente reloj, progreso, actividad y espera. JEPA comprime una traza corta en un vector; en este log regular el resumen descarta detalle temporal y añade ruido. Esto no prueba que JEPA sea inferior en general: indica que todavía no gana su complejidad sin planes, objetos, contexto o acciones reales más ricos.

8. Acciones sintéticas y world model

Las actividades públicas no se relabelaron como acciones. Se generó un overlay separado con acciones timestamped, propensión, elegibilidad, coste y efecto estructural conocido. El boosting de recuperación v1 falló correct-vs-shuffled. El Action-Event-JEPA con SIGReg mejoró en media, pero no en cada seed y colapsó. La ablation condicional VISReg se activó porque había colapso en validación.



VISReg obtiene 725.75 ± 3.20 minutos con acción correcta frente a 740.43 con acción barajada y 731.45 con prefijo solo. Correct gana en 3/3 seeds y mejora 14.67 minutos de media frente a shuffled. Sin embargo, aunque el rango efectivo sube a 15.41–16.16, la desviación media por dimensión permanece 0.020–0.023, bajo el umbral. El resultado prueba recuperación de señal inyectada, no un world model operativo estable.

9. Serving y producto recomendado

La entrada demostrable es un panel ETA/ventanas embebible en Shipping Board o Freight Intelligence. Trace Port/TWINPORTS reciben process intelligence y, cuando exista export Kaleido, tiempo restante de operación. Cada salida expone cutoff, geofence/plan visible, P50/P90, confianza/abstención, razones y fuente. El sistema continúa read-only y los escenarios permanecen separados y etiquetados como simulación.

10. Seguridad, límites y gates de piloto

- conectores y API read-only; sin endpoints de escritura ni control de equipos;
- seudonimización bajo control de Kaleido; fotos/notas fuera del primer modelo;
- planes inmutables por `valid_from`; censura explícita; split por operación;
- umbrales en validación; reference model congelado; adaptación solo shadow con rollback;
- GDPR, retención, roles y revisión de operador pendientes antes del piloto.

Lo que esto no demuestra: precisión o valor para Kaleido; generalización portuaria; desviación material; causalidad o contrafactuales; ROI, ahorro realizado, producción o despliegue exitoso.

11. Próximo paso falsable

Sesión de 90 minutos para elegir una operación repetible, usuario/buyer, desviación material, acción disponible y coste de intervenir. Solicitar esquema y 3–5 operaciones pseudonimizadas para validar semántica; después un histórico suficiente con plan original y revisiones, outcomes y acciones timestamped. Ejecutar replay shadow 4–8 semanas con gates preacordados de cobertura, falsas alertas, lead time, peor grupo y utilidad del operador.

Cierre de tarea

Hipótesis: una capa predictiva sobre posiciones y eventos puede ampliar Shipping Board, Freight Intelligence, Trace Port y TWINPORTS.

Cambios: benchmark ETA AIS con holdout futuro, benchmark OCEL objeto-céntrico, pipeline causal, JEPA/ablations, API/dashboard e informes generados.

Tests: suites unitarias/integración/adversariales, lint y typing; hashes de los runs citados verificados al generar este documento.

Evidencia: ETA boosting pasa 6/6 gates en 85 viajes futuros; el grafo OCEL y JEPA no superan sus gates; VISReg recupera señal sintética sin validar causalidad.

Limitaciones: dominio AIS de EE. UU. concentrado en Nueva Orleans; OCEL simulado; no hay datos Kaleido, outcomes materiales ni acciones reales.

Siguiente paso falsable: replay sobre export Kaleido congelado y revisión operativa.

Fuentes primarias y corporativas

- [Kaleido Trace Port – producto oficial](#)
- [Kaleido TWINPORTS – proyecto oficial](#)
- [NOAA MarineCadastre AccessAIS – fuente oficial](#)
- [NOAA AIS FAQ – cálculo de ETA y cobertura](#)
- [OCEL 2.0 Container Logistics – registro oficial](#)
- [Warehouse Outbound Event Log – DOI](#)
- [LeJEPA; LeWorldModel](#)
- [VISReg; proyecto oficial](#)
- [T-JEPA; Var-JEPA](#)